Ré-identification sans coordination dans les types de données répliquées sans conflits

Matthieu Nicolas (matthieu.nicolas@loria.fr)

Rapporteurs : Hanifa Boucheneb Professeure, Polytechnique Montréal

Davide Frey Chargé de recherche, HdR, Inria Rennes Bretagne-Atlantique

Examinateurs : Hala Skaf-Molli Maîtresse de conférences, HdR, Nantes Université, LS2N

Stephan Merz Directeur de Recherche, Inria Nancy - Grand Est

Olivier Perrin Professeur des Universités, Université de Lorraine, LORIA

Gérald Oster Maître de conférences, Université de Lorraine, LORIA



Encadrants ·







Applications collaboratives

TODO : Voir comment représenter une appli collaboratice à ce stade

 Un système collaboratif est un système supportant ses utilisateur-rices dans leurs processus de collaboration pour la réalisation de tâches.

Démocratisation des applications collaboratives

TODO: Voir comment illustrer ce point. Screenshots et nombre d'utilisateurs en-dessous?

Avantages d'une architecture basée sur le cloud...

TODO : Représenter collaboration via appli basée sur le cloud

- · Disponibilité : Répond aux utilisateur-rices
- · Tolérance aux pannes : Fonctionne malgré pannes
- · Capacité de passage à l'échelle : Supporte activité massive

... et ses limites

TODO : Illustrer chacune des propriétés

- · Confidentialité
- Souveraineté

- Pérennité
- · Résistance à la censure

Pouvons-nous concevoir des applications collaboratives satisfaisant l'ensemble de ces

propriétés?

Applications collaboratives pair-à-pair [1]

TODO : Illustrer une appli P2P

Problématiques

En l'absence d'autorités centrales, comment

- · résoudre les conflits de modifications?
- · authentifier les utilisateur-rices?
- · sécuriser les communications?

^{[1].} KLEPPMANN et al., « Local-First Software : You Own Your Data, in Spite of the Cloud ».

MUTE'



- Éditeur de texte collaboratif P2P temps réel chiffré de bout en bout
- Permet à l'équipe d'étudier et contribuer sur les problématiques des applications Local-First Software (LFS)

^{*.} Disponible à : https://mutehost.loria.fr

Mes contributions

TODO : À retravailler pour faire apparaître les problématiques ? TODO : Ajouter comparaison des modèles de sync et approches pour CRDTs pour le type Séquence ?

- Conception d'un nouveau Conflict-free Replicated Data Type (CRDT) pour le type Séquence
- · Implémentation et intégration de CRDTs dans MUTE

Type de données Séquence

TODO : Représenter une séquence, puis une exécution provoquant un conflit

- Représente une collection ordonnée et de taille dynamique d'éléments
- · Deux opérations de modifications, insert et remove
- · Modifications ne commutent généralement pas

Un mécanisme de résolution de conflits est nécessaire pour résoudre les divergences

Conflict-free Replicated Data Types (CRDTs)[2]

- · Nouvelles spécifications des types de données
- · Types de données répliquées
 - · Permettent modifications sans coordination
 - · Garantissent la convergence forte

Convergence forte

Ensemble des noeuds ayant intégrés le même ensemble de modifications obtient des états équivalents, sans nécessiter d'actions ou messages supplémentaires

^{[2].} Shapiro et al., « Conflict-Free Replicated Data Types ».

CRDTs et théorie des treillis [3]

· Reposent sur la théorie des treillis

TODO: Représenter un sup-demi-treillis

- · États ordonnés par relation ≤, avec état minimal ⊥
- · Modification d'un état génère état supérieur ou égal d'après ≤
- Existe fonction qui fusionne deux états et retourne leur borne supérieure

^{[3].} DAVEY et al., Introduction to Lattices and Order.

La fonction de fusion d'états est un mécanisme

de résolution de conflits automatique

Caractéristiques d'un CRDT

Ce qui définit un CRDT

- · Sémantique de son mécanisme de résolution de conflits
- · Modèle de synchronisation utilisé

Se focalise sur

- Spécification forte des séquences répliquées avec entrelacements [4]
- · Synchronisation par opérations

^{[4].} ATTIYA et al., « Specification and space complexity of collaborative text editing ».

LogootSplit [5]

- · CRDT pour le type Séquence
- · Appartient à l'approche à identifiants densément ordonnés

^{[5].} ANDRÉ et al., « Supporting Adaptable Granularity of Changes for Massive-Scale Collaborative Editing ».

Approche à identifiants densément ordonnés

- Assigne un identifiant de position à chaque élément de la séquence
- Utilise les identifiants des éléments pour les ordonner les uns par rapport aux autres

Propriétés des identifiants de position [6]

- Unique
- Immuable
- Ordonnable par une relation d'ordre strict total <_{id}
- · Appartenant à un espace dense

^{[6].} Preguica et al., « A Commutative Replicated Data Type for Cooperative Editing ».

Identifiant LogootSplit

- Composé d'un ou plusieurs tuples $pos_{\it offset}^{\it nodeSeq}$
- TODO : Ajouter animations pour expliciter le rôle de chaque composant

Exemple:

$$i_0^{A1}r_3^{B1}\cdots m_0^{A2}$$

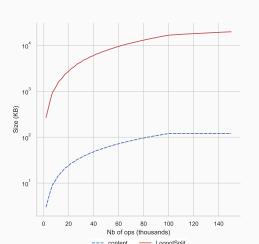


TODO : Reprendre exemple de divergence, mais avec LogootSplit pour montrer convergence

Limites de LogootSplit

- · Croissance non-bornée de la taille des identifiants
- Fragmentation en blocs courts

Taille du contenu comparé à la taille de la séquence LogootSplit



1% contenu, 99% métadonnées

Mitigation du surcoût des CRDTs pour le type Séquence

L'approche core-nebula [7]

- Ré-assigne des identifiants courts aux éléments, c.-à-d. les renomme
- Nécessite de transformer les opérations insert et remove concurrentes...
- · ...et consensus pour effectuer le renommage

Inadaptée aux systèmes P2P sujets au churn

^{[7].} ZAWIRSKI et al., « Asynchronous rebalancing of a replicated tree ».

Pouvons-nous proposer un mécanisme de

réduction du surcoût des CRDTs pour le type

Séquence adapté aux applications LFS, c.-à-d.

sans coordination synchrone?

Thanks for your attention, any questions?

